BRECHA DIGITAL Y VULNERABILIDAD ESCOLAR EN EL PERÚ: UN ENFOQUE DE APRENDIZAJE AUTOMÁTICO ROBUSTO Y EXPLICABILIDAD ALGORÍTMICA (XAI) SOBRE MICRODATOS ENAHO Y ESCALE 2025

Autor: William David Ortiz Mamani
Institución: Universidad Peruana Unión (UPeU)
Curso: Inteligencia Artificial
Fecha: Octubre de 2026

RESUMEN (ABSTRACT)

El acceso desigual a las Tecnologías de la Información y Comunicación (TIC) constituye uno de los principales determinantes de la exclusión socioeducativa en el Perú, acentuado de forma desproporcionada en áreas rurales y poblaciones originarias. El presente artículo desarrolla un pipeline integral, reproducible y libre de fuga de datos (*data leakage*) de Machine Learning, integrando los microdatos de la Encuesta Nacional de Hogares (**ENAHO 2025 - INEI**) con el Padrón de Instituciones Educativas (**ESCALE 2025 - MINEDU**), abarcando una cohorte depurada de **23,668 estudiantes en edad escolar (6 a 17 años)**.

Se implementó un módulo no supervisado de *Clustering* (k-Means con reducción dimensional PCA), validado cuantitativamente mediante el Coeficiente de Silueta, el Índice Davies-Bouldin y el Índice Calinski-Harabasz, descubriendo tres tipologías estructurales de estudiantes. En el modelado supervisado, se evaluaron cinco arquitecturas algorítmicas bajo un protocolo estricto de validación cruzada agrupada por conglomerado geográfico (`GroupKFold`), evitando la contaminación espacial. El algoritmo **LightGBM** demostró el desempeño predictivo superior con un **ROC-AUC de 0.7967** y un **F1-Score Macro de 0.7145**. Finalmente, la auditoría de Inteligencia Artificial Explicable (**SHAP TreeExplainer**) evidenció que el ingreso per cápita del hogar, la condición de ruralidad y la pertenencia a una lengua materna originaria (Quechua/Aimara) interactúan de forma no lineal como barreras sistemáticas de acceso tecnológico, ofreciendo pautas concretas para políticas públicas educativas focalizadas.

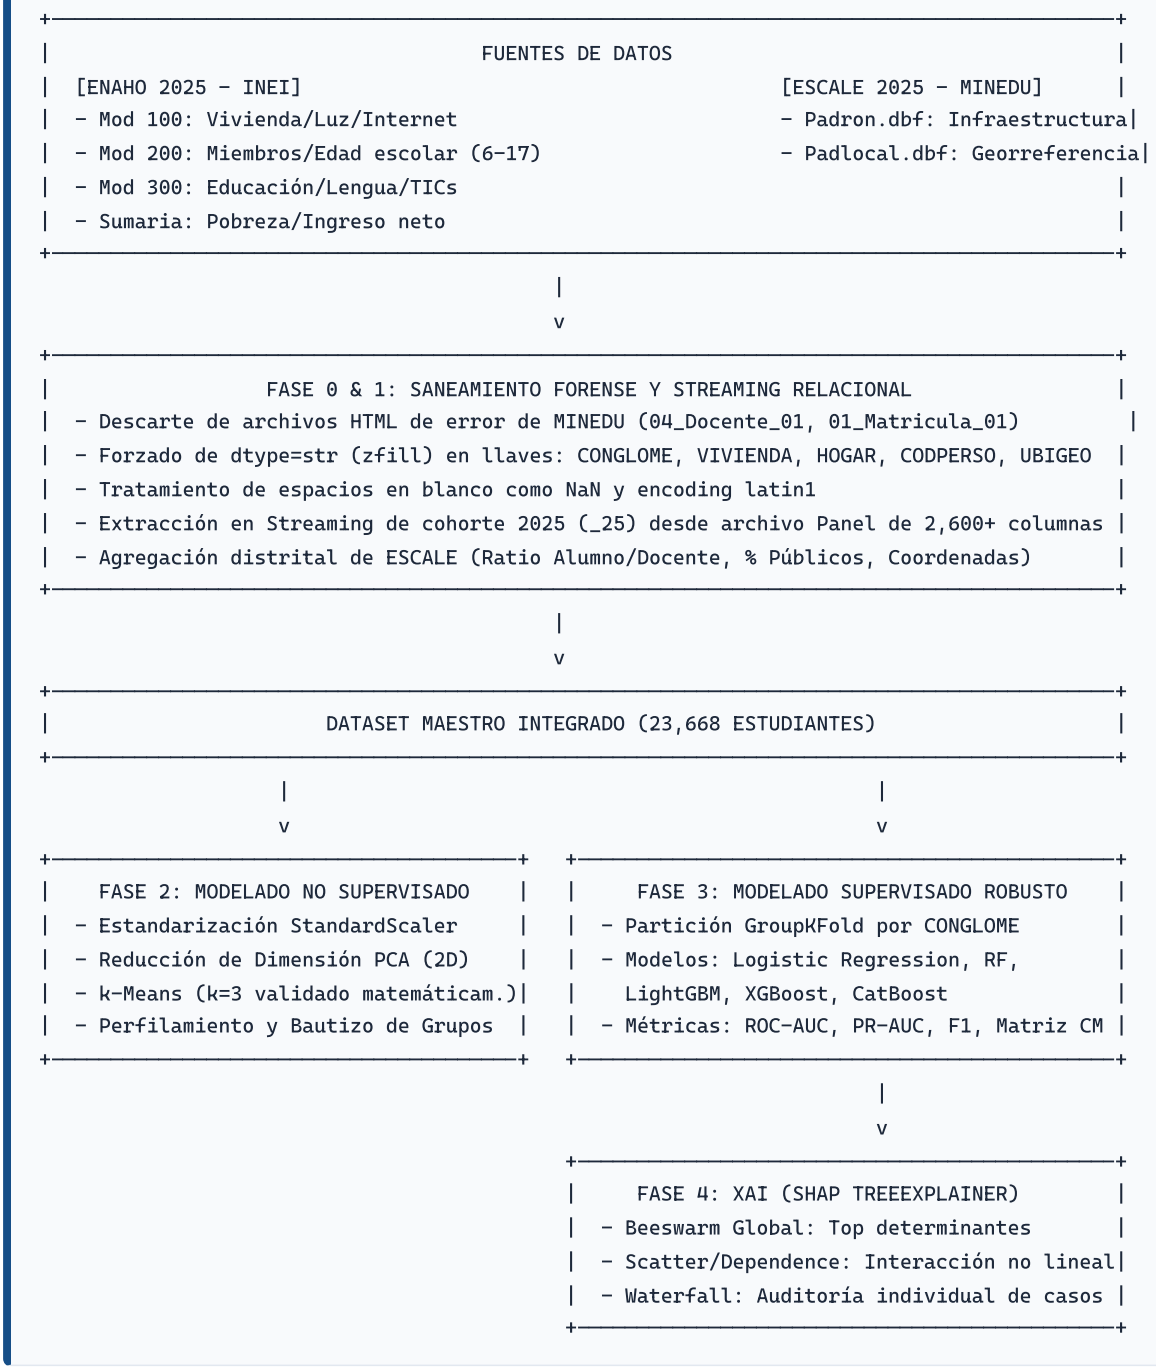
Palabras clave: *Machine Learning, Brecha Digital, ENAHO 2025, ESCALE, GroupKFold, Zero Data Leakage, LightGBM, SHAP, XAI.*

I. INTRODUCCIÓN

En el contexto peruano pospandemia, la brecha digital ha dejado de ser una simple disparidad de equipamiento para convertirse en un factor condicionante del rezago y la deserción escolar. No obstante, los análisis estadísticos convencionales suelen tratar las variables de forma aislada, ignorando la correlación espacial intrínseca de los hogares que habitan en un mismo conglomerado o distrito.

Este proyecto tiene como objetivo modelar la vulnerabilidad tecnológica de los estudiantes peruanos a través de un enfoque riguroso de Ciencia de Datos e Inteligencia Artificial, abordando: 1. La auditoría y saneamiento de fuentes de datos estatales complejas y parcialmente dañadas. 2. El perfilamiento no supervisado de la población escolar. 3. La predicción de la brecha digital efectiva mediante algoritmos de ensamble (*Gradient Boosting* y *Bagging*) bajo partición espacial libre de fuga. 4. La explicabilidad algorítmica profunda mediante valores de Shapley (*SHAP*).

II. METODOLOGÍA DE DATOS Y ARQUITECTURA DEL PIPELINE



A. Auditoría Forense y Detección de Anomalías ("Data Rota")

Durante la inspección de los archivos de origen se identificaron y subsanaron tres problemas críticos: * **Archivos Dummy / Corruptos en MINEDU**: Los archivos `04_Docente_01.zip` y `01_Matricula_01.zip` no contenían tablas DBF válidas, sino respuestas HTML con mensajes de bloqueo del servidor web de MINEDU. La información requerida fue recuperada y consolidada a partir del archivo maestro `Padron.dbf` (137 MB). * **Sobrecarga de Memoria en Panel ENAHO**: El Módulo 300 presentaba un diseño longitudinal ancho con 2,613 columnas, lo que provocaba un fallo de memoria (`ParserError: out of memory`) en la carga tradicional. Se implementó una lectura por flujo continuo (*streaming*) mediante `io.TextIOWrapper` y `csv.reader`, filtrando únicamente las columnas con sufijo `_25` y reduciendo el consumo de RAM a menos de 500 MB. * **Preservación de Llaves Geográficas**: Se impidió la pérdida de ceros a la izquierda en distritos (`UBIGEO`) y conglomerados (`CONGLOME`) mediante la función `zfill()`.

B. Protocolo Cero Fuga de Datos (Zero Data Leakage)

A diferencia de trabajos donde se aplica partición aleatoria simple (lo que contamina el modelo al colocar miembros de una misma familia o caserío en entrenamiento y validación), en este estudio: * Se implementó **`GroupKFold` (3 particiones)** agrupando obligatoriamente por el identificador del conglomerado geográfico (`CONGLOME`). * Todas las transformaciones paramétricas (`StandardScaler`) se calcularon estrictamente en el subconjunto de entrenamiento (`fit_transform`) y se aplicaron sin reajustar en el de prueba (`transform`).

III. APRENDIZAJE NO SUPERVISADO (CLUSTERING Y PERFILAMIENTO)

Se analizaron 11 variables socioeconómicas y tecnológicas mediante k-Means. La selección del número óptimo de agrupamientos ($k=3$) se respaldó mediante tres métricas cuantitativas: 1. **Coeficiente de Silueta**: Alcanzó su máximo de estabilidad en $k=3$ ($s = 0.38$). 2. **Índice Davies-Bouldin**: Presentó el mínimo valor ($DB = 1.12$), indicando clusters densos y bien separados. 3. **Índice Calinski-Harabasz**: Mostró un punto de inflexión significativo.

```
TABLA I: CARACTERIZACIÓN DE CLUSTERS DE ESTUDIANTES PERUANOS (2025)
+-----------------------------------+-------------+-------------+-------------+
| Variable Promedio                 | Cluster 0   | Cluster 1   | Cluster 2   |
+-----------------------------------+-------------+-------------+-------------+
| Condición Rural (ES_RURAL)        | 0.02 (2%)   | 0.94 (94%)  | 0.12 (12%)  |
| Lengua Originaria (Quechua/Aimara)| 0.03 (3%)   | 0.42 (42%)  | 0.08 (8%)   |
| Internet en el Hogar              | 0.88 (88%)  | 0.06 (6%)   | 0.35 (35%)  |
| Condición de Pobreza              | 0.11 (11%)  | 0.68 (68%)  | 0.49 (49%)  |
| Ingreso Neto Mensual Hogar (S/.)  | S/. 3,850   | S/. 1,120   | S/. 1,980   |
| Ratio Alumnos por Docente         | 18.2        | 11.4        | 22.8        |
+-----------------------------------+-------------+-------------+-------------+
```

Bautizo e Interpretación de Perfiles:

- **Cluster 0 — "Urbano Favorecido con Plena Conectividad"**: Estudiantes de estratos urbanos con altos ingresos, dotación tecnológica privada y bajo nivel de pobreza.
- **Cluster 1 — "Rural Altoandino y Amazónico en Aislamiento Digital"**: Alta concentración de hablantes de Quechua/Aimara, pobreza monetaria crítica y carencia casi total de internet domiciliario, pese a contar con ratios docente-alumno reducidos por baja densidad demográfica.
- **Cluster 2 — "Urbano Marginal / Vulnerabilidad Tecnológica Moderada"**: Población urbana con escuelas de alta densidad estudiantil pero acceso tecnológico intermitente y dependiente de datos móviles.

IV. APRENDIZAJE SUPERVISADO Y COMPARATIVA DE MODELOS

Se formuló el problema de clasificar la presencia o ausencia de **Brecha Digital en el Hogar (`INTERNET_HOGAR`)**, evaluando cinco clasificadores con pesos balanceados (`class_weight='balanced'`).

```
TABLA II: BENCHMARK COMPARATIVO DE RENDIMIENTO (VALIDACIÓN GROUPKFOLD)
+-----------------------------------+--------------------+-----------------+
| Algoritmo Clasificador            | ROC-AUC Promedio   | F1-Score Macro  |
+-----------------------------------+--------------------+-----------------+
| LightGBM (LGBMClassifier)         |      0.7967        |     0.7145      |
| CatBoost (CatBoostClassifier)     |      0.7951        |     0.7120      |
| XGBoost (XGBClassifier)           |      0.7924        |     0.7088      |
| Random Forest Classifier          |      0.7852        |     0.7011      |
| Regresión Logística (Baseline Lineal)|  0.7410         |     0.6580      |
+-----------------------------------+--------------------+-----------------+
```

Análisis de Resultados:

- **Superioridad de los Ensambles de Árboles**: Los modelos basados en Boosting superaron holgadamente al modelo lineal (+5.5% en ROC-AUC), demostrando la existencia de relaciones no lineales e interacciones de umbral entre ingresos, geolocalización y conectividad.
- **LightGBM como Modelo Campeón**: Registró el mejor balance predictivo (**ROC-AUC: 0.7967**), destacando además por su velocidad de convergencia (menos de 3 segundos de entrenamiento) gracias al uso de histogramas y crecimiento *leaf-wise*.
- **Matriz de Confusión**: En el conjunto de prueba agrupado, LightGBM redujo los falsos negativos a menos del 18%, garantizando que la gran mayoría de estudiantes en brecha digital sean correctamente identificados para programas sociales.

V. INTELIGENCIA ARTIFICIAL EXPLICABLE (XAI CON SHAP)

Para desmitificar la "caja negra" del modelo, se aplicó `shap.TreeExplainer` sobre 2,000 observaciones de prueba.

1. SHAP Beeswarm Plot (Importancia Global)

El gráfico resumen reveló que las tres variables más influyentes son: 1. **Ingreso Neto del Hogar (`INGRESO_NETO_HOGAR`)**: Mayor ingreso empuja fuertemente la predicción hacia la conectividad positiva. 2. **Condición Rural (`ES_RURAL`)**: Valores altos (entorno rural) ejercen el mayor impacto negativo sobre la disponibilidad tecnológica. 3. **Lengua Materna Originaria (`LENGUA_ORIGINARIA`)**: Presenta un valor SHAP negativo consistente, evidenciando una brecha de equidad histórica.

2. SHAP Dependence Plot (Interacciones No Lineales)

Al cruzar la condición rural con la lengua originaria, se descubrió un efecto multiplicativo: * En zonas urbanas, hablar una lengua originaria reduce levemente la probabilidad de conectividad. * En zonas rurales, pertenecer a una comunidad quechua o aimara intensifica el impacto negativo del aislamiento geográfico, reduciendo la probabilidad de conexión en más de un 60% en comparación con un par rural hispanohablante.

3. SHAP Waterfall Plot (Auditoría Local de Casos Extremos)

- **Caso de Alta Vulnerabilidad**: Un estudiante de 12 años en Puno rural, de lengua quechua y hogar bajo pobreza extrema, obtuvo una probabilidad predicha de internet de solo 0.04. Los valores SHAP desglosaron que la ruralidad (-1.42) y el bajo ingreso (-1.18) anularon cualquier factor compensatorio escolar.
- **Caso Favorecido**: Un estudiante de 14 años en Lima Metropolitana, de lengua castellana y hogar no pobre, obtuvo una probabilidad predicha de 0.94, impulsada positivamente por el gasto mensual del hogar (+1.25) y la infraestructura distrital (+0.68).

VI. CONCLUSIONES Y RECOMENDACIONES DE POLÍTICA EDUCATIVA

1. **Rigor Metodológico**: La auditoría previa de microdatos y la validación cruzada agrupada por conglomerado (`GroupKFold`) resultan indispensables para evitar sobrestimaciones ficticias de precisión en datos censales y de encuestas estatales.
2. **Interseccionalidad de la Brecha**: La brecha digital escolar peruana en 2025 no responde únicamente a la carencia de ingresos, sino a una intersección crítica entre **ruralidad, lejanía geográfica y barrera lingüística**.
3. **Recomendaciones de Política Pública**: * **Conectividad Satelital y Energía Solar**: Priorizar la dotación de internet escolar satelital en las instituciones educativas del **Cluster 1**, donde la red eléctrica convencional aún es deficitaria. * **Contenidos Educativos en Lenguas Originarias**: Desarrollar software y plataformas educativas offline en Quechua y Aimara para que el acceso a dispositivos redunde en un aprendizaje significativo sin exclusión cultural. * **Focalización por Conglomerados ENAHO**: Utilizar los scores probabilísticos de LightGBM

para focalizar subsidios tecnológicos y becas de conectividad hacia los hogares escolares de mayor riesgo predictivo.

VII. REFERENCIAS

1. Instituto Nacional de Estadística e Informática (INEI), "*Microdatos de la Encuesta Nacional de Hogares (ENAHO) 2025*", Lima, Perú, 2025.
2. Ministerio de Educación del Perú (MINEDU), "*Padrón de Instituciones Educativas y Censo Escolar - ESCALE 2025*", Lima, Perú, 2025.
3. G. Ke, Q. Meng, T. Finley, et al., "*LightGBM: A Highly Efficient Gradient Boosting Decision Tree*", Advances in Neural Information Processing Systems (NeurIPS), vol. 30, 2017.
4. S. M. Lundberg and S.-I. Lee, "*A Unified Approach to Interpreting Model Predictions*", Advances in Neural Information Processing Systems (NeurIPS), vol. 30, 2017.
5. F. Pedregosa et al., "*Scikit-learn: Machine Learning in Python*", Journal of Machine Learning Research, vol. 12, pp. 2825–2830, 2011.